# **GPUL XIII Xornadas Libres**



## Creación de un clúster de Hadoop con Cloudera

David Albela Pérez (@elmadno)









### Licencia



Creación de un clúster de Hadoop con Cloudera by David Albela Pérez is licensed under a Creative Commons Reconocimiento-CompartirIgual 4.0 Internacional License.









# Índice

- Introducción
- Arquitectura
- Requisitos
- Instalación
- HDFS
- MapReduce
- Ecosistema
- Alta Disponibilidad
- Resumen









### Computación distribuida

- Procesamiento paralelo en varios cientos o miles de nodos
  - Frameworks como Open MPI o PVM
- Enfocados a distribuir la carga de procesamiento
  - Nodos con alto poder computacional
  - Sistemas separados del almacenamiento

#### **Problemas**

- Cuello de botella con gran cantidad de datos
- Hardware caro y programas complejos con sincronización









### Grace Murray Hopper

- "In pioneer days they used oxen for heavy pulling, and when one ox couldn't budge a log, they didn't try to grow a larger ox"
- "We shouldn't be trying for bigger computers, but for more systems of computers."











### Hadoop

- Inspirado en los papers de GFS y MapReduce
- Escalabilidad horizontal
  - Comunicación entre nodos mínima
  - Añadir más nodos incrementa la capacidad y rendimiento
- Construido para commodity hardware









### Hadoop

- Plataforma Open Source Java para soluciones Big Data
- Doug Cutting (Lucene, Nutch)
- Componentes
  - Commodity Hardware
  - Sistema de ficheros distribuido (HDFS)
  - Paradigma MapReduce
- Amplio ecosistema (Sqoop, Hive, Pig, Hbase, Mahout, etc.)









#### Historia

- 2003, Paper Google File System
- 2004, Paper MapReduce publicado por Google
- 2004, Doug Cutting trabajando en Google crea la base de Hadoop para Nutch
- 2006-2008, Doug Cutting se une a Yahoo (web search index)
- Marzo 2006, Apache Hadoop 0.1.0
  - Hadoop es el nombre del peluche de su hijo, un elefante amarillo









#### Historia

- 2007-2008, The New York Times "convierte" 150 años de historia con Amazon EC2/S3 y Hadoop
  - TIFFs → PDF
    - 4TB + 1.5TB en S3
    - 11M artículos
    - 100 instancias
    - 24 horas
  - Timemachine
    - 405.000 TIFF+XML → PNG+JSON
    - 3,3M de artículos en SGML
    - 36 horas









#### Historia

- 2009, 3 ingenieros crean Cloudera, más tarde se une Doug Cutting y otros ingenieros como Tom White
- 2010, Framework MapReduce algormitmos genéticos
- 2012, Informe Gartner 4.4M Jobs for Big Data
- 2014, A lot of Startups for Big Data
  - ScalingData 'Killer-app' (email, mensajería instantánea, videojuegos online)
  - SNAP, AmpLAB (Berkeley)









### SNAP, ampLab (Berkeley) 2014

- Secuenciador de alineamiento de ADN Open Source
  - http://snap.cs.berkeley.edu/
- Profesor David Patterson (Berkeley, ampLab)
  - RISC, RAID
- Apache Spark (alternativa MapReduce x100 in memory)
  - Integrado con Hadoop 2 YARN
- Caso de Joshua Osborn
  - En solo 90 min. aisló elementos del ADN
  - El 0.2% pertenecían a una bacteria extraña
- Búsqueda para cura contra el cáncer









#### **SNAP**

SNAP is built on Spark, and it's already saving lives. Patterson spoke about a recent case where a boy in Wisconsin was suffering from a mysterious illness that had him trapped in a coma for weeks with brain swelling. He was sent to the University of California, San Francisco, where doctors worked with Patterson and AMPLab to process a sample of his DNA using SNAP. In about 90 minutes, the computer had isolated all the human elements, leaving just the .02 percent that wasn't. It belonged to a rare bacterium, which was treated immediately.

"How do you find the needle in the haystack?" Patterson asked. "Get rid of all the hay."









#### Cloudera

- Soporte de Apache Hadoop a empresas
- Certificaciones y cursos para Hadoop
- Modelo de negocio freemium
- CDH (Cloudera Distribution Including Apache Hadoop)
  - Distribución de Open Source
  - Paquetes RPM y Deb (Debian/Ubuntu/Suse)
  - Cloudera Manager

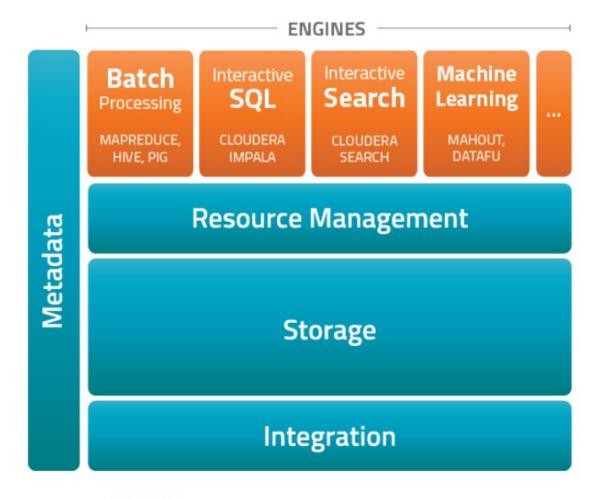








#### Cloudera CDH



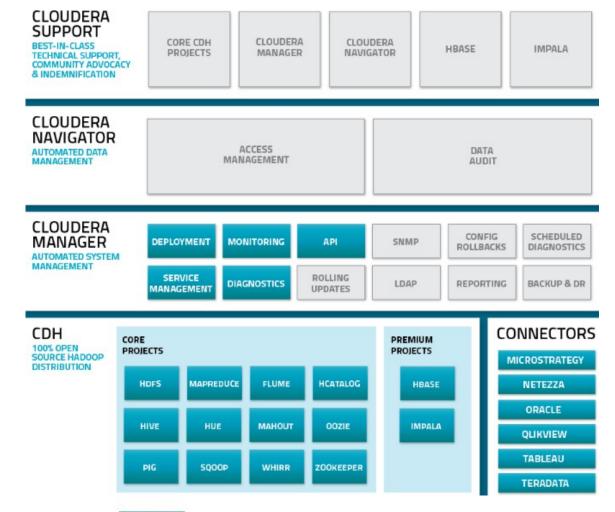








#### Cloudera Standard











#### **HortonWorks**

- Alternativa a Cloudera
- Fundada en 2011
- Servicio HDP análogo a CDH de Cloudera
- Certificaciones
- Partners como Yahoo, Microsoft, Red Hat o SAP
- Integración y soporte en muchas aplicaciones

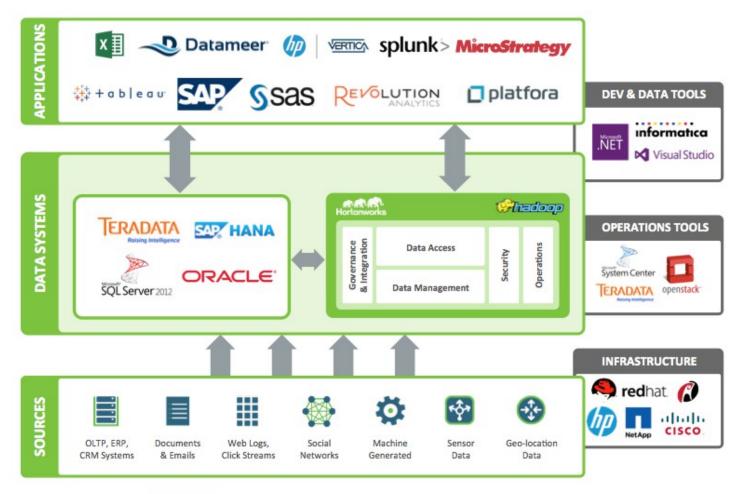








#### **HortonWorks**





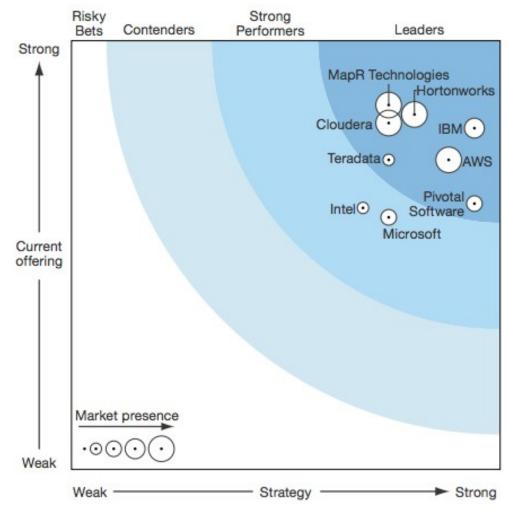






#### Mercado

- Cloudera y HortonWorks:
   líderes de mercado
- Informe Forrester Research Q1 2014:
  - Big Data Hadoop Solutions











# Índice

- Introducción
- Arquitectura
- Requisitos
- Instalación
- HDFS
- MapReduce
- Ecosistema
- Alta Disponibilidad
- Resumen

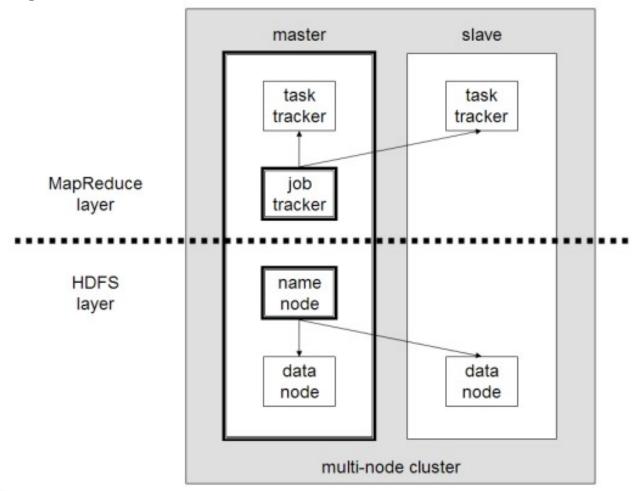








#### Arquitectura











#### Arquitectura

- Almacenar y procesar los datos en los mismos nodos
- Planificación de trabajo "data locality"
  - Procesamiento en el mismo nodo donde están los datos
- Separación de los datos bloques (64-128 Mbytes)
  - 1000 discos (210MB/s) en paralelo
  - Lectura 3TB en 15 seg.
- Replicación
  - Mismo bloque replicado en 3 nodos









#### Arquitectura

- Programación en Java al igual que Hadoop
  - Soporta otros lenguajes (Python, PHP, C, etc.)
- Simplificación del procesamiento
  - Trabajo Map(k1, v1) → list(k2, v2)
  - Recopilación intermedia y envío
  - Trabajo Reduce(k2, list(v2)) → list(v3)









#### Componentes HDFS

#### NameNode

- Nodo maestro de HDFS
- Almacena Metadatos
  - FSImage (checkpoint)
  - Edits (edit logs)

#### DataNode

- Nodos esclavos
- Almacenan los bloques









#### Componentes HDFS

#### **Secundary NameNode**

- Liberar carga al NameNode
- Copia de respaldo de FSImage
  - Siempre en nodo alternativo a NameNode
- Aplica los últimos cambios en FSImage
  - Cada hora
  - Cada 64MBytes









#### Componentes MapReduce

#### **JobTracker**

- Gestor de los trabajos MapReduce
- Hasta 4 intentos por cada trabajo
  - En cada nodo que contiene el dato
- Registra el progreso de los trabajos

#### **Tasktracker**

- Ejecuta un trabajo sobre un bloque
- Intenta lanzarse sobre el DataNode que tiene el dato









#### Alta Disponibilidad

- NameNode Active
- NameNode Standby
  - Sustituye al SecondaryNameNode pero con HA
- JournalNode
  - Almacenan los metadatos de los NameNode
  - Al menos 1/3 deben estar levantados
- ZooKeeper
  - Cuidador del ecosistema de Hadoop
  - Habilitar Failover en HA
    - Por defecto es manual









# Índice

- Introducción
- Arquitectura
- Requisitos
- Instalación
- HDFS
- MapReduce
- Ecosistema
- Alta Disponibilidad
- Resumen









### Requisitos

- NameNode/Jobtracker
  - Requiere gran cantidad de memoria
    - 8-16 Gb
- DataNode/Tasktracker
  - 2-4 discos SAS/SSD
    - ilmportante! No RAID
  - Dual-Quad core
    - 2 tareas por Tasktracker









### Requisitos

- Imágenes VM de Cloudera
  - http://www.cloudera.com/content/cloudera/en/downloads/quickstart\_vms/cdh-4-7-x.html
- VirtualBox, KVM o VMWare Player
  - En el taller usaremos VirtualBox
- OS 64-bit
  - 2 cores
  - 4Gb-8Gb RAM
  - 15Gb-30 Gb espacio libre en disco









#### 4 VMs

- Configuración básica
  - 768MB-1536 MB de RAM
  - 1 core
- NAT en eth1
- Hostname: eth2 (internal network)
  - elephant: 192.168.0.1/24
  - tiger: 192.168.0.2/24
  - horse: 192.168.0.3/24
  - monkey: 192.168.0.4/24

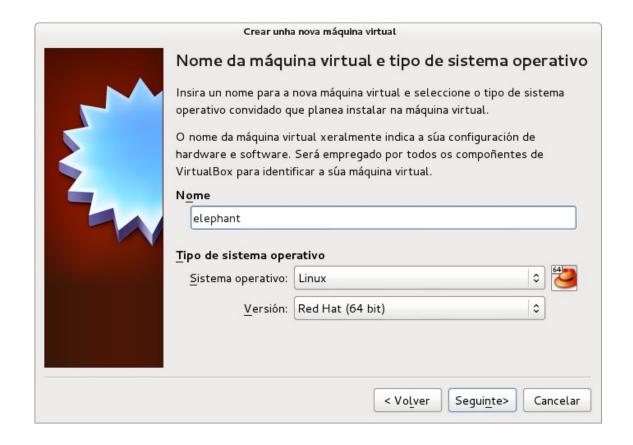








#### Importar VM base











#### Importar VM base











#### Importar VM base



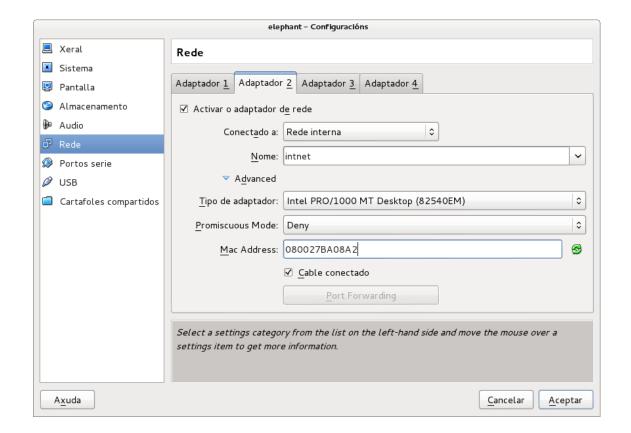








### Adaptador de Red











# Índice

- Introducción
- Arquitectura
- Requisitos
- Instalación
- HDFS
- MapReduce
- Ecosistema
- Alta Disponibilidad
- Resumen









#### Instalación

- Configuración idioma teclado y zona horaria
- Actualización de paquetes
  - \$ yum update -y
- Instalación de vi mejorado (opcional)
  - \$ yum install nano vim emacs -y
- Detener los servicios de Cloudera Manager
  - Servicio web parando todos los procesos
  - Eliminar servicio en arranque

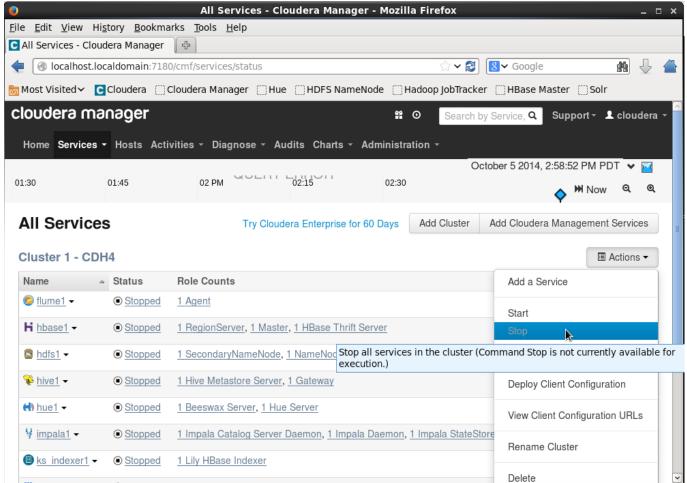








## Eliminar Cloudera Manager











## Eliminar pseudo-distribuido

- Cloudera Quickstart incluye paquetes pseudo-distribuidos
  - sudo yum remove -y hadoop-0.20-conf-pseudo
- Crear configuración base inicial
  - sudo mv /etc/hadoop/conf /etc/hadoop/conf.alternatives
  - \$ sudo mv /etc/hadoop/conf.empty /etc/hadoop/conf
  - + touch /etc/hadoop/conf/hadoop-env.sh









## Re-instalar paquetes

- Es necesario reinstalar los paquetes básicos
- Incluyen la configuración de ficheros y servicios
  - \$ sudo yum reinstall -y hadoop-hdfs-namenode hadoop-hdfsdatanode hadoop-0.20-mapreduce-tasktracker hadoop-hdfssecondarynamenode hadoop-0.20-mapreduce-jobtracker
- Habilitar arranque de los servicios
  - \$ for s in `cd /etc/init.d/; Is hadoop\*`; do sudo chkconfig \$s on; done









## Configuración de Red

- Configurar tarjeta de red eth1
  - Configuración por defecto (NAT)
  - Gestionada por Network-Manager
    - /etc/sysconfig/network-scripts/ifcfg-eth1

```
DEVICE="eth1"
TYPE=Ethernet
B00TPR0T0="dhcp"
NM_CONTROLLED="yes"
DEFROUTE=yes
IPV4_FAILURE_FATAL=yes
IPV6INIT=no
NAME="eth1"
ONB00T=yes
```









## Configuración de Red

- Configurar tarjeta de red eth2
  - /etc/sysconfig/network-scripts/ifcfg-eth2

```
DEVICE="eth2"
TYPE=Ethernet
B00TPR0T0="static"
NM_CONTROLLED="no"
IPADDR=192.168.1.1
PREFIX=24
DEFROUTE=yes
IPV4_FAILURE_FATAL=yes
IPV6INIT=no
NAME="eth2"
ONB00T=yes
```









## Configuración de Red

- Configurar hosts del cluster
  - /etc/hosts
    - 192.168.1.1 elephant
    - 192.168.1.2 tiger
    - 192.168.1.3 horse
    - 192.168.1.4 monkey
- Configurar hostname
  - /etc/sysconfig/network
    - NETWORKING=yes
    - HOSTNAME=elephant









### Clonar VM

- Apagar elephant
  - System → Shut down
- Clonar desde VirtualBox
  - Machine → Clone...
  - Marcar "Reinitialize the MAC address of all network cards"
  - Full clone (copiar los discos)









# Índice

- Introducción
- Arquitectura
- Requisitos
- Instalación
- HDFS
- MapReduce
- Ecosistema
- Alta Disponibilidad
- Resumen









## HDFS (Hadoop Distributed FileSystem)

- Separa los datos en bloques (64-128 Mbytes)
- Acceso secuencial
  - Única escritura y lectura secuencial
  - Append (HBase)
- NameNode guarda los metadatos
  - Nombre fichero, permisos, fechas
  - Block-ids: bloques del fichero y que DN lo tienen
- DataNode almacena los bloques
  - Replicación x3

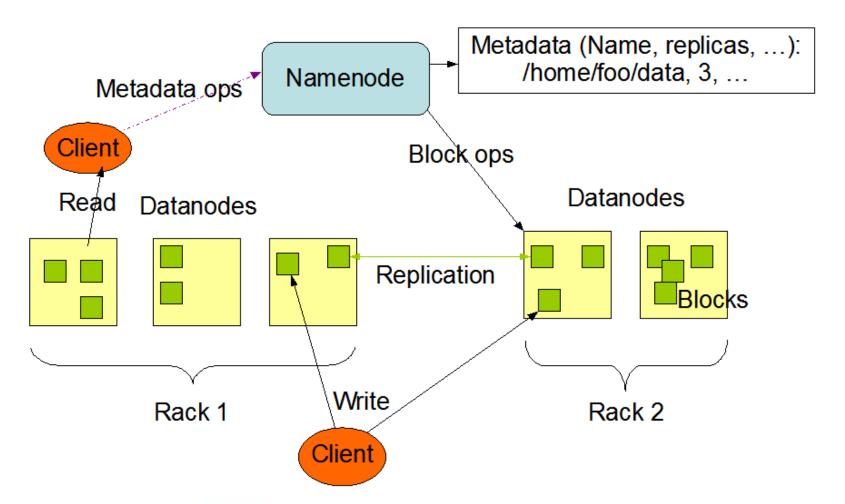








#### **HDFS Architecture**











### Características

- Data locality
- Rack-aware
  - Replica dos bloques en otro mismo rack
- Switch-aware
  - x máquinas en switches distintos, réplicas en distintas LAN
- Anatomy File Read
  - Hadoop pide información al NameNode
  - El NN devuelve los DN en orden de cercanía









### NameNode

- Los bloques nunca pasan por el NameNode
  - Se transfieren entre DataNodes o al cliente
- Memory Allocation
  - Memoria suficiente en el NN para guardar los metadatos:
    - 150-200 bytes / ítem
    - 1 ítem / file metadata
    - 1 ítem / bloque
  - ¿Por qué Hadoop es óptimo para ficheros grandes?
    - Fichero 1Gb / 128Mb por bloque = 8 bloques = 9 ítems
    - Fichero 1Gb / 1Mb por bloque = <u>1025 ítems</u>









### NameNode

- Si se cae, no hay acceso al HDFS
  - Hadoop soporta Federación de NameNode
    - Útil si no se tiene suficiente memoria física.
  - Almacena Metadatos
    - FSImage (checkpoint)
    - Edits (edit logs)
  - Opción recomendada Alta Disponibilidad
    - NameNode active y standBy
    - JournalNodes (al menos 3)
    - Failover automático con ZooKeeper









### DataNode

- Almacenamiento
  - Bloques de datos
  - Pueden ir en distintos discos
    - Sin RAID
  - Guarda un checksum del bloque
    - Verificación del bloque: lectura
- Enviá heartbeart al NN para indicar disponibilidad
  - Si en 10 min. el NN no detecta un DN → DN muerto
    - NN solicita réplicar los bloques del DN muerto
    - El bloque pasa de DN a DN, nunca por NN









## Configuración

- core-site.xml
  - fs.default.name: hdfs://elephant:8020
    - Identifica el NameNode
- hdfs-site.xml
  - dfs.name.dir: /disk1/dfs/nn,/disk2/dfs/nn
    - Ruta de los metadatos de NameNode
  - dfs.data.dir: /disk1/dfs/dn,/disk2/dfs/dn
    - Ruta de los datos de DataNode (más checksum)
  - dfs.http.address: elephant:50070
    - Servicio web información HDFS









## Otros parámetros

- core-site.xml
  - hadoop.tmp.dir
    - Ruta temporal, por defecto /tmp/hadoop-\${user-hadoop}
- hdfs-site.xml
  - dfs.block.size
    - Tamaño bloque de datos, por defecto 64Mb
  - dfs.replication
    - Número de bloques replicados, por defecto 3
  - dfs.datanode.du.reserved
    - Espacio reservado por disco no ocupado por los bloques de HDFS en los DataNodes. Recomendable al menos 10Gb









### Iniciar servicios

#### elephant

- Namenode
  - # service hadoop-hdfs-namenode start
- tiger
  - Secundary NameNode
    - # service hadoop-hdfs-secundarynamenode start
- All nodes
  - DataNode
    - # service hadoop-hdfs-datanode start









# Índice

- Introducción
- Arquitectura
- Requisitos
- Instalación
- HDFS
- MapReduce
- Ecosistema
- Alta Disponibilidad
- Resumen









### Características

- Paralelización automática y distribuída
- Tolerancia a fallos
- Herramientas de monitorización
- Soporte para cualquier lenguaje con Hadoop Streaming
- Los datos intermediarios se escriben en el disco local
- Terminología
  - Job: Mapper, Reducer y una lista de entradas
  - **Task**: Unidad de trabajo
  - Un Job se divide en Tasks

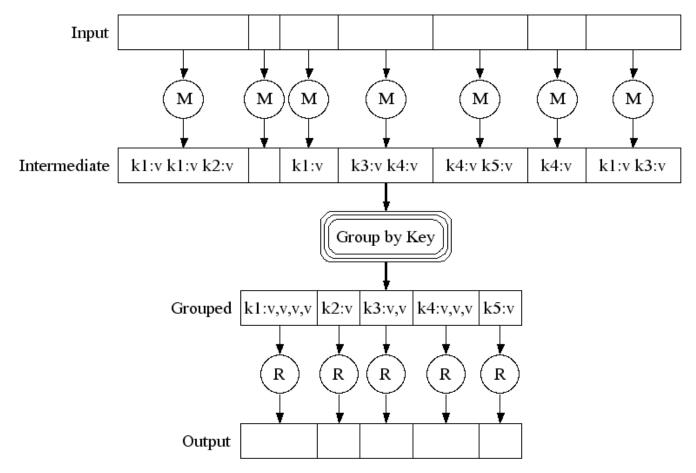








## MapReduce











### Fases

#### Mapper

Input: datos de origen

Output: clave, valor

#### Shuffle & sort

Reordenación de los datos salida de Map

#### Reduce

- Input: salida Mapper reordenados
- Output: clave, valor resultado esperado
- Tasks: Las define el desarrollador









## Componentes

#### JobTracker

- Gestiona los trabajos MapReduce
- Si una tarea falla, se encarga de lanzarla de nuevo
- Soporta HA
  - JobTracker Activo y Standby

#### TaskTracker

- Ejecuta las tareas MapReduce en un nodo
- Cada TaskTracker ejecuta por defecto 2 tareas
- Envía heartbeats al JobTracker









### Versiones

#### MRv1

- MapReduce clásica
- Normalmente un solo JobTracker
- Limitación de 1000 nodos para el JobTracker

#### MRv2 / YARN

- JobTracker → Resource Manager
- TaskTracker → NodeManager
  - Actúa como JobTracker en el nodo
- Ventaja: RM solo reparte la carga entre los distintos nodos









## Configuración

- mapred-site.xml
  - mapred.local.dir
    - Rutal local para fichero intermediarios
  - mapred.job.tracker
    - Especifica el JobTracker
  - mapred.system.dir
    - Ruta de ficheros compartidos durante la ejecución
  - mapreduce.jobtracker.staging.root.dir
    - Ficheros de configuración en HDFS









## Otros parámetros

- mapred-site.xml
  - mapred.tracktracker.map.task.maximum
    - Nº máximo de tareas Map (40-60)
  - mapred.tracktracker.reduce.task.maximum
    - Nº máximo de tareas Reduce (1.5 \* cores)









### Iniciar servicios

- horse
  - JobTracker
    - # service hadoop-0.20-mapreduce-jobtracker start
- All nodes
  - TaskTracker
    - # service hadoop-0.20-mapreduce-tasktracker start









# Índice

- Introducción
- Arquitectura
- Requisitos
- Instalación
- HDFS
- MapReduce
- Ecosistema
- Alta Disponibilidad
- Resumen

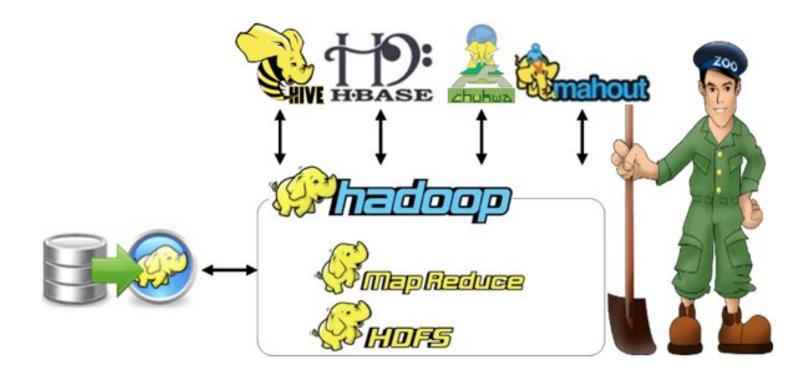








### Ecosistema











### **Ecosistema**

- Data Integration
  - Flume, Sqoop
- Batch Processing
  - Hive, Pig
- Database NoSQL
  - HBase
    - NoSQL column-oriented
- Machine Learning & Data Mining
  - Mahout









### Flume

- Integración de Datos
  - Cada servidor enviar sus logs a unos o varios agentes Flume
  - Soporta encriptado y compresión
- Agente
  - Almacena los datos en memoria
  - Envía a HDFS cuando alcanza un tamaño
- Canales de memoria
  - Establece tamaño caché
  - Comunica Agente con la fuente origen y el HDFS
    - Data Serialization Avro, Thift

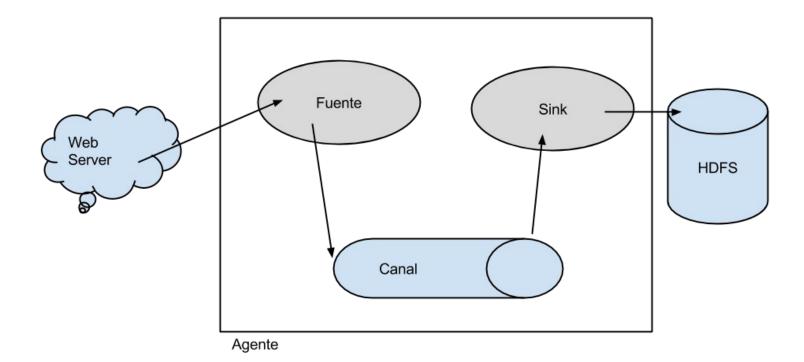








### **Flume**











## Sqoop

- Integración de Datos
  - BD relacional ↔ HDFS
  - Soporte JDBC
    - Descargar el driver para el SGBD
      - Para MySQL /usr/share/java/mysql-connector-java.jar
    - Conectores alternativos (Netezza, Teradata, etc.)
- Sqoop ver. 2
  - Funciona como servicio
    - Disponible desde varios clientes
    - Requiere del driver JDBC en los clientes
    - Interfaz web: WebHDFS o Http FS









## Sqoop

- Instalación
  - \$ yum install -y sqoop
  - Is /usr/share/java/mysql-connector-java.jar
- Importación tabla de MySQL
  - \$ sqoop import \
- --connect jdbc:mysql://localhost/myDatabase \
- --table myTable --fields-terminated-by '\t' \
- --username myUser --password myPassword









### Hive

- Desarrollado en Facebook para análisis de datos
- HiveQL
  - Consultas SQL sobre HDFS
    - Selects con Joins, Group by, Having, Order By
  - Lanza trabajos MapReduce

#### MetaStore

- Gestor de metadatos en DB relacional (MySQL, Derby)
- MetaStore Local
- Shared MetaStore
  - Múltiples usuarios ejecutan Hive compartido

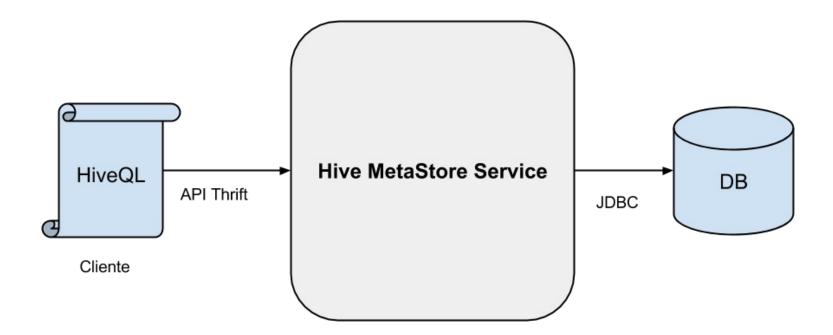








## Hive











### Hive

- Instalación
  - \$ sudo yum install -y hive mysql-server libmysql-java
  - Crear MetaStore
    - mysql> create database metastore;
    - Schema /usr/lib/hive/scripts/metastore/upgrade/mysql/hiveschema-0.10.0.mysql.sql;
  - Configurar Hive
    - /etc/hive/conf/hive-site.xml









# Pig

- Desarrollado por Yahoo! Para análisis de datos
- Alternativa a Hive
  - No usa sentencias SQL
- Pig Latin
  - Lenguaje de control de flujo
  - Define bolsas a través del intérprete Grunt
  - Soporta JOINs y filtros
  - Sentencia STORE almacena el resultado en HDFS









# Pig

- Instalación
  - \$ yum install -y pig
- Ejemplo
  - \$ pig
  - Definir bolsas:
    - grunt> texts = LOAD 'binary\_texts' AS (id\_text:int, binary\_file\_id:int, english:chararray, spanish:chararray, created\_date:chararray);
    - grunt> files = LOAD 'binary\_files' AS (id\_file:int, file:chararray, desc:chararray);









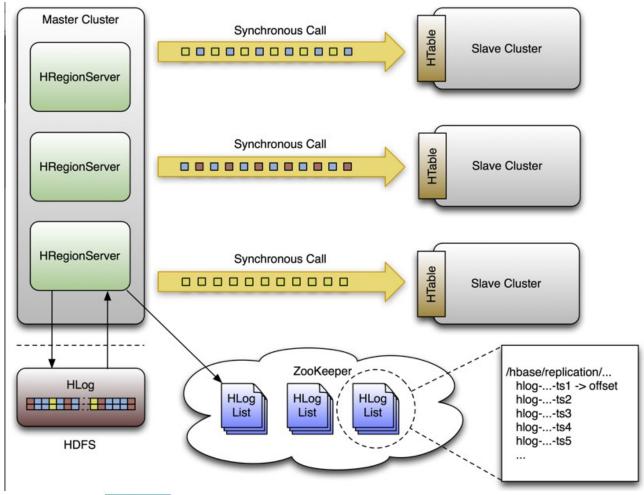
- Bases de datos NoSQL
  - Orientado a columnas
- Sobre HDFS
  - Permite almacenar datos de poco tamaño
  - Operaciones APPEND
  - Familias de tablas
- Integración con Hive y Pig
- Acceso
  - hbase shell, Java API, Thrift, RESTful



















#### ZooKeeper

- Servicio centralizado de alta disponibilidad
- Gestiona el cluster de HBase

#### HBase Master

Nodo maestro para el cliente Hbase

#### HBase RegionServer

- Recide los datos y procesa las peticiones
- Solo en nodos esclavos









- Instalación
  - sudo yum install -y hbase zookeeper-server hbasemaster hbase-regionserver
- Configuración
  - Por defecto Standalone
  - /etc/hadoop/conf/hdfs-site.xml
    - dfs.datanode.max.xcievers
      - Límite ficheros que puede servir a la ver (4096)
    - hbase.cluster.distributed
      - Habilitar HBase en modo distribuido
    - hbase.rootdir
      - Ruta en HDFS de los datos de HBase









- Ejemplos
  - Crear tabla test
    - \$ hbase shell
    - hbase> create 'test', 'data'
  - Insertar filas
    - hbase> put 'test', 'row1', 'data:1', 'value1'
  - Verificar tabla
    - hbase> scan 'test'
  - Obtener fila
    - hbase> get 'test', 'row1'









#### Hue

- Contenedor web de aplicaciones de Hadoop
- Gestión de grupos y usuarios
- Hace más cómodo el uso de herramientas de Hadoop











### Hue

- Herramientas
  - Hive UI
  - Impala UI
  - File Browser
  - Job Browser
  - Job Designer
  - Oozle Workflow Editor
  - Shell UI









#### Hue

- Instalación
  - \$ sudo yum install -y hue
  - sudo service hue start
- Configuración
  - /etc/hadoop/conf/hdfs-site.xml
    - dfs.webhdfs.enable
      - Habilitar con "yes" el acceso HDFS
  - /etc/hue/hue.ini
    - webhdfs\_url=http://elephant:14000/webhdfs/v1/
    - jobtracker\_host=horse
    - server\_host=elephant









### **Mahout**



- Herramienta para Machine-Learning
- Facilita la extración de conocimiento
- Incluye algoritmos para Data Mining
  - Recomendación de objetos
  - Clustering o agrupamiento
  - Clasificación
  - Frecuencias de objetos









### **Mahout**

- Integración con Scala & Spark
  - write one, run everywhere
  - Alternativa distribuida para R
- Ejemplos
  - http://mahout.apache.org/users/classification/breimanexample.html









# Índice

- Introducción
- Arquitectura
- Requisitos
- Instalación
- HDFS
- MapReduce
- Ecosistema
- Alta Disponibilidad
- Resumen









## Alta Disponibilidad

- Si el NameNode cae
  - No se tiene acceso al clúster HDFS
  - SecundaryNameNode solo replica FSImage
- Si el JobTracker cae
  - No se pueden lanzar trabajos MapReduce









# Alta Disponibilidad

- NameNode with HA
  - NameNode Active
  - NameNode StandBy
    - SecundaryNameNode no se usa
- JournalNode
  - Almacena los metadatos
    - Los NN necesitan los metadatos actualizados siempre
  - Más de la mitad por cada NN
- ZooKeeper
  - Failover automático

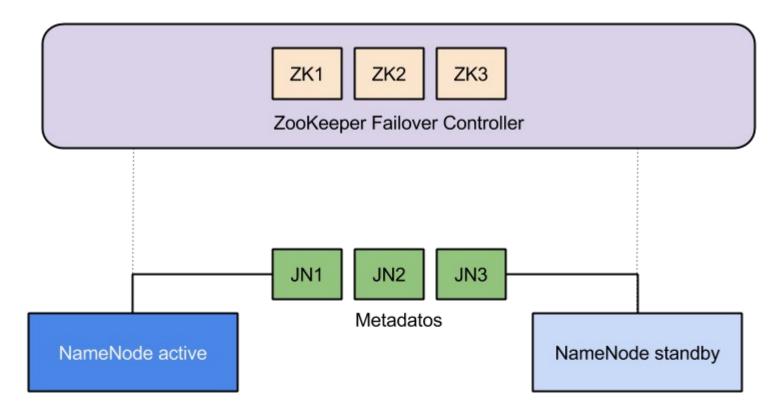








# Alta Disponibilidad











#### Resumen

- Hemos visto
  - Componentes básicos de Hadoop
  - Configuración en modo clúster
  - HDFS
  - Paradigma MapReduce
  - Algunas aplicaciones del ecosistema de Hadoop
  - Configuración alta disponibilidad









# Seguridad

- Cualquiera con acceso al clúster
  - Controlar el acceso a los datos
  - No hay autenticación de usuario
    - \$ sudo -u hdfs hadoop fs -ls -R /
  - No soporta cifrado de disco en CDH4
- Soluciones
  - Aislar el clúster
  - Configurar Kerberos
    - http://www.cloudera.com/content/cloudera/en/document ation/cdh4/latest/CDH4-Security-Guide/CDH4-Security-Guide.html









- http://hadoop.apache.org
- http://cutting.wordpress.com
- http://www.cloudera.com/content/cloudera/en/documentation/cd h4/latest/
- http://hortonworks.com
- http://www.gartner.com/newsroom/id/2207915
- https://gigaom.com/2013/03/04/the-history-of-hadoop-from-4nodes-to-the-future-of-data/
- http://blogthinkbig.com/hadoop-open-source-big-data/
- https://gigaom.com/2014/08/02/the-lab-that-created-sparkwants-to-speed-up-everything-including-cures-for-cancer/









- http://wikibon.org/wiki/v/The\_Hadoop\_Wars:\_Cloudera\_and\_Hort onworks%E2%80%99\_Death\_Match\_for\_Mindshare
- http://open.blogs.nytimes.com/2007/11/01/self-service-proratedsuper-computing-fun/
- http://open.blogs.nytimes.com/2008/05/21/the-new-york-timesarchives-amazon-web-services-timesmachine/
- http://www.norbertogallego.com/cloudera-punta-de-lanza-debig-data/2013/07/19/
- http://www.cs.yale.edu/homes/tap/Files/hopper-wit.html
- http://research.google.com/archive/mapreduce-osdi04slides/index-auto-0007.html









- https://forxa.mancomun.org/projects/mapreduceags/
- https://musicbrainz.org/
- http://db-engines.com/en/system/Cassandra%3BHBase %3BMongoDB
- http://www.bdisys.com/27/1/17/BIG%20DATA/HADOOP
- http://www.cloudera.com/content/cloudera/en/training/library/ap ache-hadoop-ecosystem.html









- http://gethue.com/
- http://pig.apache.org
- http://hive.apache.org
- http://sqoop.apache.org
- http://hbase.apache.org
- http://mahout.apache.org
- http://flume.apache.org







